

文献紹介: Aspect Based Sentiment Analysis with Gated Convolutional Networks

安藤 智大†

† 東京農工大学大学院 工学府




図 1: Aspect 分類の手法

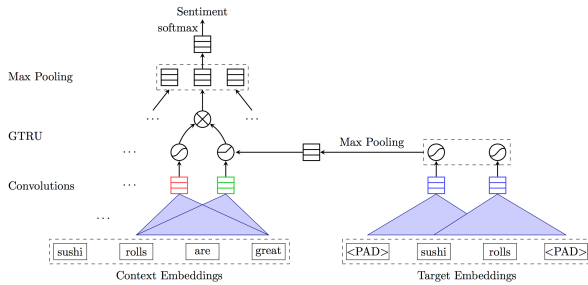


図 2: Target 分類の手法

本報告書では、Aspect sentiment classification の近年の研究傾向についてサーベイした結果を記す [1].

1 概要

ACL2018 の Long-Paper, 先行研究のほとんどが LSTM と attention メカニズムを用いているが, 複雑かつ多大な訓練時間を要するという課題を持つ. 本書ではゲート付き畳み込みニューラルネットによってより正確かつ効率的な手法を提案する. まず, 新たに定義したゲート付き Tanh-ReLU ユニットが, 与えられた aspect 及び文書全体に対して選択的に感情特徴を出力することを可能にする. また, 畳み込み層は LSTM のような時間依存性が無く, ゲートもまた独立に機能するため, モデルの計算は容易に並列化できるようになる. 実験では, SemEval データセットに対して効率的かつ効果的であることを示した.

†ando@katfujii.lab.tuat.ac.jp
©藤田桂英研究室. 再配布厳禁.

Models	Restaurant-Large		Restaurant 2014	
	Test	Hard Test	Test	Hard Test
SVM*	-	-	75.32	-
SVM + lexicons*	-	-	82.93	-
ATAE-LSTM	83.91±0.49	66.32±2.28	78.29±0.68	45.62±0.90
CNN	84.28±0.15	50.43±0.38	79.47±0.32	44.94±0.01
GCN	84.48±0.06	50.08±0.31	79.67±0.35	44.49±1.52
GCAE	85.92±0.27	70.75±1.19	79.35±0.34	50.55±1.83

表 1: Aspect 分類の結果

2 手法の要約

2.1 Gated Convolutional Network with Aspect Embedding

提案モデルは, 畳み込み層とゲーティングユニットによって構成される. 図 1 は Aspect 分類における手法のモデルを示す. まず単語埋め込みは, 事前学習及びファインチューニングがされた埋め込みベクトルを利用する. 畳み込み層では, パラメータ k を幅とした n -gram によってそれぞれベクトルから単一の特徴 c に畳み込む. これは次式で一般化される.

$$c_i = f(X_{i:i+K} * W_c + b_c) \quad (1)$$

本手法では, Gated Tanh-ReLU Units(GTRU) を上位層に設けることによって次の 3 式で構成される.

$$a_i = \text{relu}(X_{i:i+K} * W_a + V_a v_a + b_a) \quad (2)$$

$$s_i = \tanh(X_{i:i+K} * W_s + b_s) \quad (3)$$

$$c_i = s_i \times a_i \quad (4)$$

ここで v_a とは対象の aspect の埋め込みベクトルである. a_i と s_i を同時に考慮することで感情的特徴と aspect の特徴を同時に学習する. その後, max-over-time pooling 層によって固定長ベクトルに変換される. このベクトルを softmax 関数によって確率値に変換し, 交差エントロピーによって誤差を求め学習を行う.

2.2 Target 分類に対する GCAE

図 2 は, 先程提案したネットワーク構造を Target 分類に拡張したモデルである. これは Target である語句に対し別途で小さな CNN を設けて, その pooling によって得られた特徴を relu に渡すベクトルとして変更した構造となっている.

3 実験と結果

Aspect 分類の実験では SemEval2014 の Restaurant データセットと 2014-2016 のデータに拡張した Restaurant-

Models	Restaurant		Laptop	
	Test	Hard Test	Test	Hard Test
SVM*	77.13	-	63.61	-
SVM + lexicons*	80.16	-	70.49	-
TD-LSTM	73.44±1.17	56.48±2.46	62.23±0.92	46.11±1.89
ATAE-LSTM	73.74±3.01	50.98±2.27	64.38±4.52	40.39±1.30
IAN	76.34±0.27	55.16±1.97	68.49±0.57	44.51±0.48
RAM	76.97±0.64	55.85±1.60	68.48±0.85	45.37±2.03
GCAE	77.28±0.32	56.73±0.56	69.14±0.32	47.06±2.45

表 2: Target 分類の結果

Large データセットを用いる。Target 分類では, Restaurant データセットに加え, Laptop データセットを用いる。双方の実験では, 「1 文書において複数の aspect/target が出現し, かつそれらの感情極性が異なる文書」のみをデータセットとして用いた高難易度実験も同時に行う。

表 1, 表 2 はそれぞれ Aspect 分類と Target 分類の実験結果である。その他, ゲートを変更した比較情報や, 各手法における訓練が収束するまでの時間の比較などが記されていたが, 今回は割愛する (いずれも提案手法が最善の結果になっていることが示されていた)。

4 個人的見解

比較的シンプルで強い結果を残したのがやはり大きいと感じる。訓練にかかる時間の比較などは他の論文では行っていないため穴を突いた印象。しかしベースラインの SVM+感情極性辞書がかなり良い結果であることが気になった。辞書はシンプルながら強力であることが各所で示されているため, なんとか手法に融合できないものかと思う。

参考文献

- [1] Wei Xue and Tao Li. Aspect based sentiment analysis with gated convolutional networks. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 2514–2523. Association for Computational Linguistics, 2018.